


【pytorch08】 Dataset and Dataloader

2026年9月10日 17:02

• 三个核心术语:

- **Epoch**: 全部训练样本完成一次前向 + 一次反向;
- **Batch-Size**: 一次前反向所用的样本数;
- 双层嵌套: 外层epoch 内层mini-batch
- **Iteration**: 用 batch_size 个样本做一次 pass 的次数 ($= \text{总样本数} / \text{batch_size}$) 。
- Eg 10000样本 1000 Batch-size
- 10 Iteration



- **Dataset (抽象类)**: 自定义数据集需继承并实现:
 - `__getitem__(self, index)`:
 - 支持 `dataset[index]` 索引取样本;
 - `__len__(self)`: 返回数据集长度。
- **DataLoader**: 自动按 batch 取数, 参数:
 - `batch_size`: 每批样本数;
 - `shuffle`: 是否**打乱** (训练集 True, 测试集 False) ;
 - `num_workers`: 多进程加载进程数。
- **Windows 下的 num_workers**: Windows 多进程用 spawn 而非 fork, 需用 `if __name__ == '__main__':` 包裹主逻辑, 否则报 RuntimeError。
- **训练循环改造**: `for i, data in enumerate(train_loader, 0), inputs, labels = data`, 然后四步法。
- **内置数据集**: MNIST、Fashion-MNIST、CIFAR、EMNIST、COCO、ImageFolder 等, 配合 `torchvision.datasets + transforms` 使用。